DATA DRIVEN DECISIONS

Sommersemester 2026

Datenmanagement & -analyse

Prof. Dr. Christoph M. Flath

Data Driven Decisions Group, Universität Würzburg

Agenda

1. Rückblick & ORDER BY
2. DISTINCT & LIKE
3. NULL-Werte verstehen
4. Visualisierung: Streudiagramme
5. Zusammenfassung

Lernziele

Daten sortieren, Duplikate entfernen, Muster finden, mit fehlenden Werten umgehen.

Agenda

Rückblick: Was wir schon können

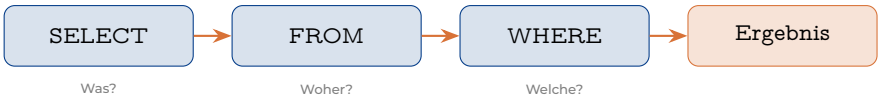

- `SELECT` – Spalten auswählen
- `WHERE` – Zeilen filtern
- `AND`, `OR`, `NOT` – Bedingungen kombinieren
- `BETWEEN`, `IN`, `LIKE` – Weitere Filter

Heute

Wie **ordnen** wir die Ergebnisse? Wie finden wir **eindeutige** Werte? Was passiert bei **fehlenden** Daten?

Neuer Datensatz: Spieltage

DATA DRIVEN DECISIONS

Letzte Woche: Finale Tabelle (1 Zeitpunkt, 18 Teams)
Diese Woche: Alle 34 Spieltage – der **Verlauf** der Saison!

```
SELECT * FROM bundesliga_spieltage LIMIT 5;
```

Spieltag	Mannschaft	Punkte_Spiel	Punkte_Kumuliert	...
1	Bayern München	3	3	...
2	Bayern München	3	6	...
3	Bayern München	1	7	...
...	...	...	...	...

Erkenntnis

Die finale Tabelle ist nur `WHERE Spieltag = 34`!

Querschnitt aus Zeitreihe

Finale Tabelle rekonstruieren:

```
SELECT Mannschaft, Punkte_Kumuliert AS Punkte
FROM bundesliga_spieltage
WHERE Spieltag = 34
ORDER BY Punkte DESC;
```

Oder: Tabelle nach Spieltag 17 (Winterpause)?

```
SELECT Mannschaft, Punkte_Kumuliert AS Punkte
FROM bundesliga_spieltage
WHERE Spieltag = 17
ORDER BY Punkte DESC;
```

⇒ Zeigt, wer zur Halbzeit vorne lag!

Warum Sortierung wichtig ist

Stellen Sie sich vor: Sie haben 1000 Kunden und wollen die Top 10 nach Umsatz.

Ohne Sortierung:

- Daten in zufälliger Reihenfolge
- Manuelles Durchsuchen nötig
- Top-Werte nicht erkennbar

Mit Sortierung:

- Höchste Werte zuerst
- Sofortige Übersicht
- Muster erkennbar

Bundesliga-Beispiel

Wer ist Tabellenführer? → Nach Punkten sortieren!
Wer steigt ab? → Nach Punkten aufsteigend, letzte 3 ansehen.

ORDER BY: Ergebnisse sortieren

DATA DRIVEN DECISIONS

Syntax

```
SELECT spalten
FROM tabelle
ORDER BY spalte [ASC|DESC];
```

Aufsteigend (Standard)

```
SELECT Mannschaft, Punkte
FROM bundesliga
ORDER BY Punkte ASC;
```

10, 15, 20, 25, ...

Absteigend

```
SELECT Mannschaft, Punkte
FROM bundesliga
ORDER BY Punkte DESC;
```

50, 45, 40, 35, ...

Merke

ASC = ascending (aufsteigend) – ist der **Default**
DESC = descending (absteigend)

ORDER BY: Schritt für Schritt

DATA DRIVEN DECISIONS

Aufgabe: Zeige die Tabelle sortiert nach Punkten (beste zuerst).

1. **Was zeigen?** → Mannschaft, Punkte
2. **Woher?** → bundesliga
3. **Wie sortieren?** → Nach Punkte, absteigend

```
SELECT Mannschaft, Punkte
FROM bundesliga
ORDER BY Punkte DESC;
```

Mannschaft	Punkte
Bayern München	50
Borussia Dortmund	42
VfB Stuttgart	36
…	…

Mehrere Sortierkriterien

Was passiert bei Gleichstand?

```
SELECT Mannschaft, Punkte, Tordifferenz
FROM bundesliga
ORDER BY Punkte DESC, Tordifferenz DESC;
```

Mannschaft	Punkte	Tordifferenz
Bayern	50	+56
Dortmund	42	+21
Hoffenheim	36	+16
Stuttgart	36	+10

Erklärung

Erst nach Punkten sortiert, bei Gleichstand (36) entscheidet die Tordifferenz. Hoffenheim vor Stuttgart wegen besserer Tordifferenz!

Sortierung: Text vs. Zahlen

Zahlen sortieren:

```
ORDER BY Punkte DESC
```

→ 50, 42, 36, 35, ...

Numerisch korrekt!

Text sortieren:

```
ORDER BY Mannschaft ASC
```

→ Augsburg, Bayern, Bochum, ...

Alphabetisch!

Achtung bei Text

- Gross-/Kleinschreibung kann relevant sein
- Umlaute: ä, ö, ü werden je nach Datenbank unterschiedlich sortiert
- Zahlen als Text: ’10’ kommt vor ’2’ (weil ’1’ < ’2’)

LIMIT: Nur die ersten N Zeilen


```sql
SELECT Mannschaft, Punkte
FROM bundesliga
ORDER BY Punkte DESC
LIMIT 5;
```

→ Die **Top 5** Teams nach Punkten

Typische Anwendungen:

- Top 10 Listen
- Stichproben ziehen
- Performance (grosse Tabellen)
- Debugging (schneller Überblick)

Mit OFFSET:

```sql
SELECT Mannschaft
FROM bundesliga
ORDER BY Punkte DESC
LIMIT 5 OFFSET 5;
```

→ Plätze 6-10

LIMIT und OFFSET verstehen

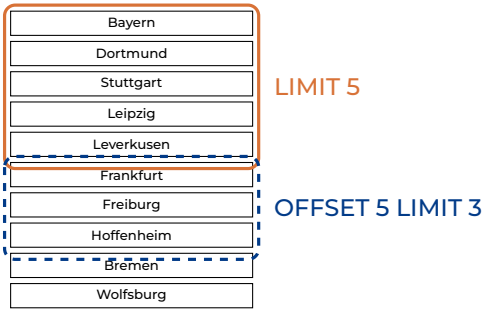


```sql
-- Top 5
SELECT * FROM bundesliga ORDER BY Punkte DESC LIMIT 5;

-- Plätze 6-8 (überspringe 5, nimm 3)
SELECT * FROM bundesliga ORDER BY Punkte DESC LIMIT 3 OFFSET 5;
```

Häufige ORDER BY Fehler

DATA DRIVEN DECISIONS

✗ **Falsch:**

Sortierung vor WHERE:

```
SELECT Mannschaft
ORDER BY Punkte
FROM bundesliga;
```

Syntax Error!

Spalte nicht im SELECT:

```
SELECT Mannschaft
FROM bundesliga
ORDER BY Punkte;
```

Funktioniert meist, aber unübersichtlich

✓ **Richtig:**

```
SELECT Mannschaft, Punkte
FROM bundesliga
ORDER BY Punkte DESC;
```

Reihenfolge

SELECT → FROM → WHERE → ORDER BY → LIMIT

Kurze Reflexion: ORDER BY

Diskutieren Sie mit Ihrem Nachbarn (2 Minuten):

1. Wann würden Sie `ASC` verwenden, wann `DESC`?
2. Was passiert, wenn Sie nach einer Spalte sortieren, die nicht im SELECT steht?
3. Wie würden Sie die “schlechtesten 3 Teams” finden?

Lösungsideen

- ASC: Alphabetisch, kleinste Werte zuerst, älteste Daten
- DESC: Ranglisten, neueste Daten, höchste Werte
- Schlechteste 3: `ORDER BY Punkte ASC LIMIT 3`

Hands-on

Daten sortieren

marimo: 02-sql-exploration.py

Aufgaben 2.1 – 2.8

Geführt → Scaffolded → Selbstständig → Debugging

Agenda

DISTINCT: Eindeutige Werte

DATA DRIVEN DECISIONS

Problem

Welche verschiedenen Werte gibt es in einer Spalte?

Ohne DISTINCT:

```
SELECT Spiele
FROM bundesliga;
```

19, 19, 18, 19, 18, 19, ...
(18 Zeilen, viele Duplikate)

Mit DISTINCT:

```
SELECT DISTINCT Spiele
FROM bundesliga;
```

18, 19
(nur 2 verschiedene Werte)

Typische Anwendungen

- Welche Kategorien gibt es?
- Welche Länder sind vertreten?
- Welche Positionen existieren bei den Spielern?

DISTINCT: Schritt für Schritt

Aufgabe: Welche verschiedenen Spielstände (Anzahl Spiele) gibt es?

1. **Was suchen wir?** → Verschiedene Werte in “Spiele”
2. **Duplikate entfernen?** → Ja, mit DISTINCT
3. **Sortieren?** → Optional, aber hilfreich

```
SELECT DISTINCT Spiele
FROM bundesliga
ORDER BY Spiele;
```

Spiele
18
19

Erkenntnis: Nicht alle Teams haben gleich viele Spiele absolviert!

DISTINCT mit mehreren Spalten


```
SELECT DISTINCT Siege, Niederlagen
FROM bundesliga;
```

→ Alle **Kombinationen** von Siege und Niederlagen

Siege	Niederlagen
16	1
12	1
11	4
11	5
...	...

Wichtig

Jede *Kombination* ist eindeutig, nicht jede Spalte einzeln!
(11, 4) und (11, 5) sind verschiedene Kombinationen.

LIKE: Mustersuche (Wiederholung & Vertiefung)

DATA DRIVEN DECISIONS

Wildcard	Bedeutung
%	Beliebig viele Zeichen (auch 0)
_	Genau ein Zeichen

```
-- Beginnt mit 'B'
WHERE Mannschaft LIKE 'B%'
```

Bayern, Bochum, Bremen, Borussia...

```
-- Endet mit 'en'
WHERE Mannschaft LIKE '%en'
```

Bremen, München, Leverkusen...

```
-- Enthält 'burg'
WHERE Mannschaft LIKE '%burg%'
```

Augsburg, Freiburg, Wolfsburg

```
-- Genau 6 Zeichen
WHERE Mannschaft LIKE '______'
```

Bayern (6 Buchstaben)

LIKE: Komplexere Muster

DATA DRIVEN DECISIONS

Zweiter Buchstabe ist 'a':

```
WHERE Mannschaft LIKE '_a%'
```

Bayern, Hamburg (falls vorhanden)

Enthält Zahl:

```
WHERE Mannschaft LIKE '%1%'
```

1. FC Union Berlin, 1. FSV Mainz 05, 1. FC Heidenheim

Beginnt mit 'B' oder 'F':

```
WHERE Mannschaft LIKE 'B%'
   OR Mannschaft LIKE 'F%'
```

Bayern, Bremen, Bochum, Frankfurt, Freiburg...

NOT LIKE:

```
WHERE Mannschaft
      NOT LIKE '%FC%'
```

Alle ohne "FC" im Namen

LIKE: Gross-/Kleinschreibung

DATA DRIVEN DECISIONS

Achtung

Je nach Datenbank ist LIKE case-sensitive oder nicht!

SQLite:

- `LIKE` ist case-**insensitive**
- `GLOB` ist case-**sensitive**

PostgreSQL:

- `LIKE` ist case-**sensitive**
- `ILIKE` ist case-**insensitive**

Sichere Lösung (funktioniert überall)

```
WHERE LOWER(Mannschaft) LIKE LOWER('%bayern%')
```

Beide Seiten in Kleinbuchstaben umwandeln!

Schnelles Quiz:

1. Was ist der Unterschied zwischen `SELECT Spiele` und `SELECT DISTINCT Spiele`?
2. Welches LIKE-Muster findet alle Teams mit “Borussia” im Namen?
   - A) `LIKE 'Borussia'`
   - B) `LIKE 'Borussia%'`
   - C) `LIKE '%Borussia%'`

Antworten

1. Ohne DISTINCT: alle Zeilen (mit Duplikaten). Mit DISTINCT: nur eindeutige Werte.
2. C – `%Borussia%` findet “Borussia” an beliebiger Stelle.

Hands-on

Eindeutige Werte & Mustersuche

marimo: 02-sql-exploration.py

Aufgaben 4.1 – 4.8

Inkl. Vorhersage-Aufgaben: Was wird das Ergebnis sein?

Pause

15 Minuten

Kaffee holen, Fragen notieren, kurz bewegen!

Agenda

1 Rückblick & ORDER BY
2 DISTINCT & LIKE
▸ **3 NULL-Werte verstehen**
4 Visualisierung: Streudiagramme
5 Zusammenfassung

Was ist NULL?

NULL bedeutet: Der Wert ist **unbekannt** oder **nicht vorhanden**.

NULL ist NICHT:

- Nicht die Zahl 0
- Nicht ein leerer String ”
- Nicht das Wort ’NULL’
- Nicht FALSE

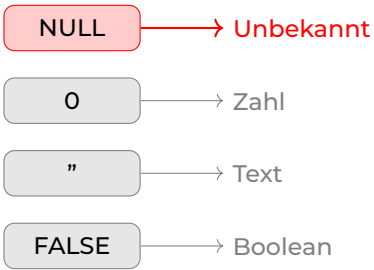

Beispiele für NULL:

- Geburtsdatum unbekannt
- Noch keine Tore geschossen (unbekannt, nicht 0!)
- Telefonnummer nicht angegeben
- Spieler hat keinen Spitznamen

Warum NULL wichtig ist

Reales Beispiel: Spieler-Datenbank

Name	Verein	Tore	Vorlagen	Spitzname
Müller	Bayern	8	4	Mülli
Neuer	Bayern	0	NULL	NULL
Gündogan	NULL	NULL	2	Günni
Musiala	Bayern	12	7	NULL

- Neuer: 0 Tore (bekannt!), Vorlagen unbekannt
- Gündogan: Verein fehlt (vereinslos?), Tore nicht erfasst
- Musiala: Hat keinen bekannten Spitznamen

Problem

Wie rechnen wir mit NULL? Was ist 5 + NULL? Was ist NULL > 10?

NULL prüfen: IS NULL / IS NOT NULL

DATA DRIVEN DECISIONS

Wichtig

= NULL funktioniert **nicht**! Verwende IS NULL.

✗ Falsch:

```
SELECT *
FROM spieler
WHERE Tore = NULL;
```

→ Liefert **keine** Ergebnisse!

Warum?

NULL = NULL ist nicht TRUE, sondern UNKNOWN!

✓ Richtig:

```
SELECT *
FROM spieler
WHERE Tore IS NULL;
```

→ Alle Spieler ohne Tor-Angabe

```
SELECT *
FROM spieler
WHERE Tore IS NOT NULL;
```

→ Alle mit Tor-Angabe

Dreiwertige Logik

Mit NULL gibt es **drei** mögliche Wahrheitswerte:

TRUE **FALSE** **UNKNOWN**

Beispiele

- `5 > 3` → TRUE
- `5 < 3` → FALSE
- `5 > NULL` → UNKNOWN (Wir wissen nicht, ob 5 größer ist!)
- `NULL = NULL` → UNKNOWN (Nicht TRUE!)

Konsequenz

`WHERE` gibt nur Zeilen zurück, bei denen die Bedingung **TRUE** ist – nicht UNKNOWN.

Wahrheitstabellen mit NULL

DATA DRIVEN DECISIONS

AND mit NULL

A	B	A AND B
T	?	?
F	?	**F**
?	?	?

FALSE “gewinnt” immer

OR mit NULL

A	B	A OR B
T	?	**T**
F	?	?
?	?	?

TRUE “gewinnt” immer

NOT mit NULL

A	NOT A
T	F
F	T
?	?

Bleibt UNKNOWN

Merkregel

? = UNKNOWN. Wenn das Ergebnis **nicht sicher** bestimmt werden kann, bleibt es UNKNOWN.
Ausnahme: FALSE AND anything = FALSE, TRUE OR anything = TRUE

COALESCE: NULL ersetzen

DATA DRIVEN DECISIONS

Syntax

```
COALESCE(wert1, wert2, wert3, ...)
```

Gibt den **ersten Nicht-NULL-Wert** zurück.

```
SELECT
    Name,
    Tore AS Tore_Original,
    COALESCE(Tore, 0) AS Tore_Bereinigt
FROM spieler;
```

Name	Tore_Original	Tore_Bereinigt
Müller	8	8
Neuer	0	0
Gündogan	NULL	0

COALESCE: Schritt für Schritt

Aufgabe: Zeige alle Spieler mit Toren, ersetze NULL durch 0.

1. **Was zeigen?** → Name und Tore
2. **NULL ersetzen?** → Ja, mit COALESCE
3. **Ersatzwert?** → 0

```
SELECT
    Name,
    COALESCE(Tore, 0) AS Tore
FROM spieler;
```

Wie COALESCE funktioniert

`COALESCE(NULL, 0)` → 0 (erster Wert ist NULL, also nimm zweiten)
`COALESCE(8, 0)` → 8 (erster Wert ist nicht NULL, nimm ihn)
`COALESCE(NULL, NULL, 5)` → 5 (erst der dritte ist nicht NULL)

COALESCE: Mehrere Fallbacks


```sql
SELECT
    Name,
    COALESCE(Spitzname, Vorname, Name) AS Anzeigename
FROM spieler;
```

Logik:

1. Wenn Spitzname vorhanden → nimm Spitzname
2. Sonst wenn Vorname vorhanden → nimm Vorname
3. Sonst → nimm Name

Name	Spitzname	Vorname	Anzeigename
Müller	Mülli	Thomas	Mülli
Neuer	NULL	Manuel	Manuel
Musiala	NULL	Jamal	Jamal

Rechnen mit NULL

Problem

Jede Rechnung mit NULL ergibt NULL!

```
-- Problem: Scorerpunkte berechnen
SELECT Name, Tore + Vorlagen AS Scorerpunkte
FROM spieler;
```

Name	Tore	Vorlagen	Scorerpunkte
Müller	8	4	12
Neuer	0	NULL	**NULL**
Gündogan	NULL	2	**NULL**

```
-- Lösung: COALESCE verwenden
SELECT Name,
       COALESCE(Tore, 0) + COALESCE(Vorlagen, 0) AS Scorerpunkte
FROM spieler;
```

Jetzt: Neuer = 0, Gündogan = 2

NULL: Zusammenfassung

Situation	Lösung
NULL prüfen	`IS NULL` / `IS NOT NULL`
NULL ersetzen	`COALESCE(wert, ersatz)`
Rechnen mit NULL	Vorher mit COALESCE ersetzen
Vergleich mit NULL	`IS NULL` (nicht = `NULL`!)

Goldene Regeln

1. NULL ist nicht 0, nicht ”, nicht FALSE – es ist **unbekannt**
2. Verwende `IS NULL`, niemals = `NULL`
3. Bei Berechnungen: erst NULL behandeln mit COALESCE
4. WHERE filtert UNKNOWN als FALSE

Hands-on

Umgang mit NULL

marimo: 02-sql-exploration.py

Aufgaben 6.1 – 6.12

40 Minuten – Debugging & Freie Exploration

Agenda

1 Rückblick & ORDER BY
2 DISTINCT & LIKE
3 NULL-Werte verstehen
▸ **4 Visualisierung: Streudiagramme**
5 Zusammenfassung

Streudiagramm: Zusammenhänge erkennen

Neu: px.scatter() – zeigt Beziehung zwischen zwei Variablen

Frage: Wer schießt viele Tore, kassiert aber auch viele?

```
SELECT Mannschaft, ToreGeschossen, ToreKassiert
FROM bundesliga;
```

```
px.scatter(ergebnis,
           x="ToreGeschossen",
           y="ToreKassiert",
           hover_name="Mannschaft",
           title="Offensive vs. Defensive")
```

⇒ Jeder Punkt = ein Team. Hover zeigt den Namen.

Streudiagramm lesen

Quadranten:

- **Oben rechts:** Viele Tore, viele kassiert
  (offensiv, aber anfällig)
- **Unten rechts:** Viele Tore, wenig kassiert
  (Spitzenteams)
- **Unten links:** Wenig Tore, wenig kassiert
  (defensiv, langweilig)
- **Oben links:** Wenig Tore, viele kassiert
  (Abstiegskandidaten)

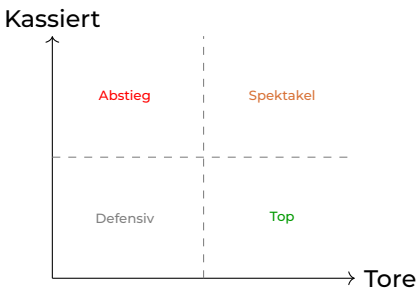

Farbe für Kategorien

Neu: color= – färbt Punkte nach einer Kategorie

```
px.scatter(ergebnis,
           x="ToreGeschossen",
           y="ToreKassiert",
           color="Liga",  -- kategoriale Variable!
           hover_name="Mannschaft")
```

Wann color= verwenden?

- Gruppen vergleichen (Liga, Position, Kategorie)
- Muster zwischen Gruppen erkennen
- **Nicht:** für kontinuierliche Werte wie Punkte

Agenda

1 Rückblick & ORDER BY
2 DISTINCT & LIKE
3 NULL-Werte verstehen
4 Visualisierung: Streudiagramme
▸ **5 Zusammenfassung**

SQL-Ausführungsreihenfolge (komplett)

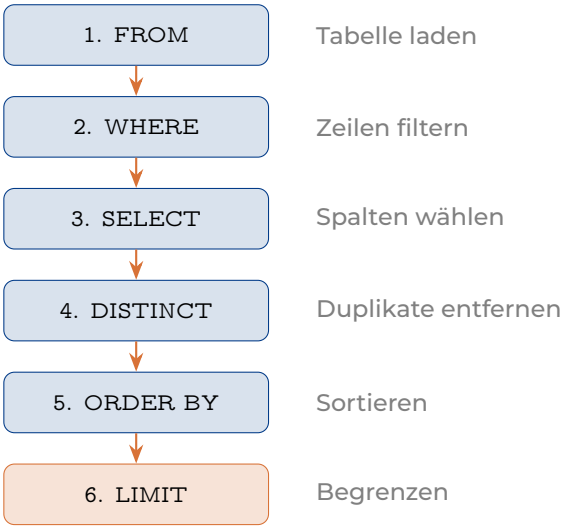

Was wir heute gelernt haben

DATA DRIVEN DECISIONS

SQL	Syntax
Aufsteigend	`ORDER BY x ASC`
Absteigend	`ORDER BY x DESC`
Begrenzen	`LIMIT n`
Überspringen	`OFFSET m`
Eindeutig	`DISTINCT`
NULL prüfen	`IS NULL`
NULL ersetzen	`COALESCE()`

Visualisierung	Funktion
Balkendiagramm	`px.bar()`
Streudiagramm	`px.scatter()`
Histogramm	`px.histogram()`
Liniendiagramm	`px.line()`
Kreisdiagramm	`px.pie()`

Workflow

SQL-Abfrage → DataFrame → Plotly Chart

Was zeigt diese Abfrage?

```
SELECT Mannschaft, Punkte FROM bundesliga ORDER BY Punkte LIMIT 3;
```

1. Die 3 Teams mit den meisten Punkten
2. Die 3 Teams mit den wenigsten Punkten
3. Die ersten 3 Teams alphabetisch
4. Einen Fehler

Was zeigt diese Abfrage?

```
SELECT Mannschaft, Punkte FROM bundesliga ORDER BY Punkte LIMIT 3;
```

1. Die 3 Teams mit den meisten Punkten
2. **Die 3 Teams mit den wenigsten Punkten**
3. Die ersten 3 Teams alphabetisch
4. Einen Fehler

Erklärung

`ORDER BY Punkte` ohne ASC/DESC sortiert **aufsteigend** (ASC ist Default).
Also: kleinste Werte zuerst → Abstiegskandidaten!

Was ist das Ergebnis von:

```
SELECT * FROM spieler WHERE Tore > 5 OR Tore <= 5;
```

1. Alle Spieler
2. Nur Spieler mit Tore-Wert (nicht NULL)
3. Nur Spieler mit mehr als 5 Toren
4. Leeres Ergebnis

Was ist das Ergebnis von:

```
SELECT * FROM spieler WHERE Tore > 5 OR Tore <= 5;
```

1. Alle Spieler
2. **Nur Spieler mit Tore-Wert (nicht NULL)**
3. Nur Spieler mit mehr als 5 Toren
4. Leeres Ergebnis

Erklärung

Wenn Tore NULL ist:
`NULL > 5` → UNKNOWN
`NULL <= 5` → UNKNOWN
`UNKNOWN OR UNKNOWN` → UNKNOWN
WHERE filtert UNKNOWN als FALSE → Zeile wird nicht angezeigt!

Was gibt `COALESCE(NULL, NULL, 'Hallo', 'Welt')` **zurück?**

1. NULL
2. 'Hallo'
3. 'Welt'
4. 'Hallo Welt'

Was gibt `COALESCE(NULL, NULL, 'Hallo', 'Welt')` **zurück?**

1. NULL
2. **'Hallo'**
3. 'Welt'
4. 'Hallo Welt'

Erklärung

COALESCE gibt den **ersten Nicht-NULL-Wert** zurück:

- Argument 1: NULL → weiter
- Argument 2: NULL → weiter
- Argument 3: 'Hallo' → **gefunden!**

'Welt' wird gar nicht mehr betrachtet.

Konzept	Syntax
Aufsteigend sortieren	`ORDER BY spalte ASC`
Absteigend sortieren	`ORDER BY spalte DESC`
Top N	`ORDER BY spalte DESC LIMIT N`
Bottom N	`ORDER BY spalte ASC LIMIT N`
Plätze X bis Y	`LIMIT (Y-X+1) OFFSET (X-1)`
Eindeutige Werte	`SELECT DISTINCT spalte`
Muster (beginnt mit)	`LIKE 'Text%'`
Muster (enthält)	`LIKE '%Text%'`
Muster (endet mit)	`LIKE '%Text'`
NULL finden	`WHERE spalte IS NULL`
Nicht NULL	`WHERE spalte IS NOT NULL`
NULL ersetzen	`COALESCE(spalte, ersatz)`

Ausblick: Vorlesung 3

DATA DRIVEN DECISIONS

Vorlesung 3: Aggregation & Gruppierung

- Aggregatfunktionen: `COUNT`, `SUM`, `AVG`, `MIN`, `MAX`
- Gruppierung mit `GROUP BY`
- Filter auf Gruppen mit `HAVING`
- Unterschied `WHERE` vs. `HAVING`

Vorgeschmack

- Wie viele Teams haben mehr als 10 Siege? → COUNT
- Was ist der Punktedurchschnitt? → AVG
- Wie viele Tore wurden insgesamt geschossen? → SUM
- Welches Team hat die meisten Tore? → MAX

Fragen?

marimo: 02-sql-exploration.py

Weiter experimentieren!