DATA DRIVEN DECISIONS

Sommersemester 2026

Datenmanagement & -analyse

Prof. Dr. Christoph M. Flath
Lehrstuhl für Wirtschaftsinformatik und Business Analytics

Julius-Maximilians-Universität Würzburg

Agenda

Rückblick: Der Weg zu SQL-Tabellen

Letzte Session:

- ER-Modell → Relationales Schema
- Primär- und Fremdschlüssel
- CREATE TABLE mit Constraints

Diese Session:

- Wann ist ein Schema “gut”?
- Systematische Qualitätsprüfung: **Normalformen**

Motivation: Wann ist ein Schema “gut”?

Probleme bei schlechtem Design:

- **Redundanz** – Daten mehrfach gespeichert
- **Änderungsanomalie** – Inkonsistenz bei Updates
- **Einfügeanomalie** – Fehlende Daten blockieren
- **Löschanomalie** – Ungewollter Datenverlust

Ziel:
Schema so gestalten, dass diese Probleme **nicht auftreten können**.

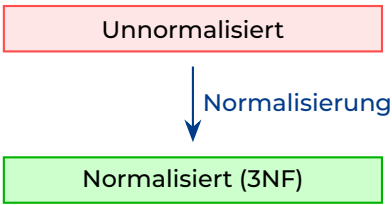

Normalisierung = systematisches Verfahren zur Beseitigung von Redundanzen

Beispiel: Unnormalisierte Tabelle

Bestellung_Unnorm

Best_Nr	Kunde	K_Stadt	Produkt	P_Preis	Menge
1001	Müller	München	Laptop	999	1
1001	Müller	München	Maus	29	2
1002	Schmidt	Berlin	Laptop	999	1
1003	Müller	München	Tastatur	79	1

Probleme:

- “Müller, München” steht **dreimal** (Redundanz)
- “Laptop, 999” steht **zweimal** (Redundanz)
- Wenn Müller umzieht: **3 Zeilen** ändern (Änderungsanomalie)
- Neuer Kunde ohne Bestellung? **Nicht möglich** (Einfügeanomalie)

Die drei Anomalien im Detail

DATA DRIVEN DECISIONS

Änderungsanomalie:

Müller, München

Müller, München Inkonsistent!

Müller, Berlin

Update vergessen → Widerspruch in den Daten

Einfügeanomalie:

Neuer Kunde

Bestellung = ?

NULL nicht erlaubt!

Neuer Kunde ohne Bestellung nicht speicherbar

Löschanomalie:

~~Letzte Bestellung~~

von Schmidt

Kundendaten weg!

Bestellung löschen → Kundendaten verloren

Kernproblem

Alle Anomalien entstehen durch **Redundanz** – die gleiche Information an mehreren Stellen.

Weiteres Beispiel: Bibliothekssystem

Ausleihe_Unnorm

Ausleihe_Nr	Leser	L_Adresse	Buch	Autor	Datum
501	Anna	Hauptstr. 1	SQL Guide	Meier	01.03.2026
502	Anna	Hauptstr. 1	Python Basics	Schmidt	05.03.2026
503	Ben	Bahnweg 7	SQL Guide	Meier	10.03.2026
504	Anna	Hauptstr. 1	Java Kompakt	Müller	12.03.2026

Identifizieren Sie die Redundanzen:

- Anna's Adresse erscheint _____ mal
- Der Autor von "SQL Guide" erscheint _____ mal
- Was passiert, wenn Anna umzieht?
- Was passiert, wenn wir die letzte Ausleihe von Ben löschen?

Agenda

Funktionale Abhängigkeit (FD)

DATA DRIVEN DECISIONS

Definition

Ein Attribut B ist **funktional abhängig** von A (geschrieben: A → B), wenn zu jedem Wert von A **genau ein** Wert von B gehört.

Beispiele:

- Matrikelnr → Studentenname ✓
- PLZ → Ort ✓ (in Deutschland)
- Ort → PLZ ✗ (München hat viele PLZ)
- ISBN → Buchtitel ✓

“Wenn ich A kenne, kenne ich auch B.”

Verschiedene Notationen (alle äquivalent):

Schreibweise	Bedeutung
$A \rightarrow B$	A bestimmt B
$A \rightarrow B$	A bestimmt B
B ist FD von A	B hängt funktional von A ab
$A \rightarrow B, C$	A bestimmt sowohl B als auch C
$A, B \rightarrow C$	Die Kombination von A und B bestimmt C

Wichtig:

- $A \rightarrow B$ bedeutet **nicht** $B \rightarrow A$
- Der Pfeil zeigt die **Richtung** der Abhängigkeit
- Die linke Seite heisst **Determinante**

FDs in unserem Beispiel

Bestellung_Unnorm(Best_Nr, Kunde, K_Stadt, Produkt, P_Preis, Menge)

Funktionale Abhängigkeiten:

- Best_Nr, Produkt → Menge (Schlüssel!)
- Best_Nr → Kunde, K_Stadt (Bestellung → Kunde)
- Kunde → K_Stadt (Kunde → Stadt)
- Produkt → P_Preis (Produkt → Preis)

Problem

Es gibt FDs, die **nicht vom gesamten Schlüssel** abhängen!
Das ist die Ursache für Redundanz.

Übung: FDs identifizieren

Mitarbeiter(MA_Nr, Name, Abteilung, Abt_Leiter, Projekt, Stunden)

MA_Nr	Name	Abteilung	Abt_Leiter	Projekt	Stunden
101	Anna	IT	Dr. Weber	Portal	20
101	Anna	IT	Dr. Weber	App	15
102	Ben	HR	Dr. Klein	Portal	30
103	Carla	IT	Dr. Weber	App	25

Welche FDs gibt es? (Ankreuzen)

- ☐ MA_Nr → Name
- ☐ MA_Nr → Abteilung
- ☐ Abteilung → Abt_Leiter
- ☐ MA_Nr, Projekt → Stunden
- ☐ Projekt → Stunden

Lösung: FDs identifizieren

Mitarbeiter(MA_Nr, Projekt, Name, Abteilung, Abt_Leiter, Stunden)

Funktionale Abhängigkeiten:

- ✓ MA_Nr → Name – Ein MA hat genau einen Namen
- ✓ MA_Nr → Abteilung – Ein MA ist in genau einer Abteilung
- ✓ Abteilung → Abt_Leiter – Jede Abteilung hat einen Leiter
- ✓ MA_Nr, Projekt → Stunden – Schlüssel-FD
- ✗ Projekt → Stunden – Falsch! Verschiedene MAs arbeiten unterschiedlich lange

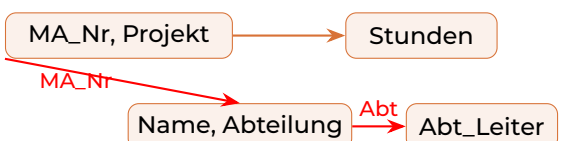

Volle vs. Partielle Abhängigkeit

Volle funktionale Abhängigkeit:
B ist **voll** funktional abhängig von A, wenn B von A abhängt, aber **nicht** von einer echten Teilmenge von A.

Beispiel:
Best_Nr, Produkt → Menge
→ Menge hängt vom **gesamten** Schlüssel ab.

Partielle Abhängigkeit:
B hängt nur von einem **Teil** des Schlüssels ab.

Beispiel:
Best_Nr → Kunde
→ Kunde hängt nur von Best_Nr ab, nicht von Produkt.

Das verursacht Redundanz!

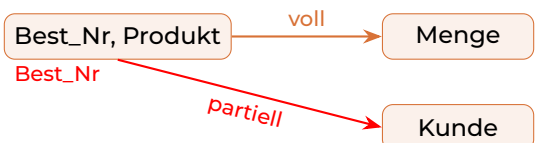

Regeln zur Herleitung von FDs:

1. Reflexivität

Wenn $B \subseteq A$, dann gilt $A \rightarrow B$

Beispiel: Vorname, Nachname → Nachname

2. Augmentation (Erweiterung)

Wenn $A \rightarrow B$, dann gilt auch $A, C \rightarrow B, C$

Beispiel: Aus MA_Nr → Name folgt MA_Nr, Projekt → Name, Projekt

3. Transitivität

Wenn $A \rightarrow B$ und $B \rightarrow C$, dann gilt $A \rightarrow C$

Beispiel: MA_Nr → Abteilung und Abteilung → Leiter ⇒ MA_Nr → Leiter

Diese drei Axiome sind *vollständig* – alle ableitbaren FDs lassen sich damit herleiten!

Nützliche Zusatzregeln (ableitbar aus den Axiomen):

Vereinigung:
Wenn A → B und A → C,
dann A → B, C

Beispiel:
ISBN → Titel und ISBN → Autor
⇒ ISBN → Titel, Autor

Dekomposition:
Wenn A → B, C,
dann A → B und A → C

Beispiel:
MA_Nr → Name, Abteilung
⇒ MA_Nr → Name und MA_Nr → Abteilung

Pseudotransitivität

Wenn A → B und B, C → D, dann A, C → D

Quiz: Welche FDs sind ableitbar?

Gegeben:

- $A \rightarrow B$
- $B \rightarrow C$
- $C, D \rightarrow E$

Welche FDs können abgeleitet werden?

FD	Ableitbar?	Begründung
$A \rightarrow C$		

Quiz: Welche FDs sind ableitbar?

Gegeben:

- $A \rightarrow B$
- $B \rightarrow C$
- $C, D \rightarrow E$

Welche FDs können abgeleitet werden?

FD	Ableitbar?	Begründung
$A \rightarrow C$	✓	Transitivität: A→B→C
$A, D \rightarrow E$		

Quiz: Welche FDs sind ableitbar?

DATA DRIVEN DECISIONS

Gegeben:

- $A \rightarrow B$
- $B \rightarrow C$
- $C, D \rightarrow E$

Welche FDs können abgeleitet werden?

FD	Ableitbar?	Begründung
$A \rightarrow C$	✓	Transitivität: A→B→C
$A, D \rightarrow E$	✓	Pseudotrans.: A→C, CD→E
$B \rightarrow E$		

Quiz: Welche FDs sind ableitbar?

Gegeben:

- $A \rightarrow B$
- $B \rightarrow C$
- $C, D \rightarrow E$

Welche FDs können abgeleitet werden?

FD	Ableitbar?	Begründung
$A \rightarrow C$	✓	Transitivität: A→B→C
$A, D \rightarrow E$	✓	Pseudotrans.: A→C, CD→E
$B \rightarrow E$	✗	D fehlt für C,D→E
$A \rightarrow B, C$		

Quiz: Welche FDs sind ableitbar?

Gegeben:

- $A \rightarrow B$
- $B \rightarrow C$
- $C, D \rightarrow E$

Welche FDs können abgeleitet werden?

FD	Ableitbar?	Begründung
$A \rightarrow C$	✓	Transitivität: A→B→C
$A, D \rightarrow E$	✓	Pseudotrans.: A→C, CD→E
$B \rightarrow E$	✗	D fehlt für C,D→E
$A \rightarrow B, C$	✓	Vereinigung: A→B, A→C

Hands-on

Funktionale Abhängigkeiten erkennen

marimo: 08-normalisierung.py

Aufgabe 8.1: FDs aus Beispieldaten ableiten

Agenda

Erste Normalform (1NF)

DATA DRIVEN DECISIONS

Definition: 1NF

Eine Relation ist in **1NF**, wenn alle Attributwerte **atomar** sind (keine Listen, keine geschachtelten Strukturen).

Nicht in 1NF:

Student	Kurse
Anna	DMA, BWL, Statistik
Ben	DMA

✗ "Kurse" enthält eine **Liste**

In 1NF:

Student	Kurs
Anna	DMA
Anna	BWL
Anna	Statistik
Ben	DMA

✓ Jede Zelle enthält **einen** Wert

Merke

1NF ist die **Mindestanforderung** für relationale Datenbanken!

1NF-Verletzungen erkennen

Typische Anzeichen:

- Komma-separierte Werte: “München, Berlin, Hamburg”
- Nummerierte Spalten: Telefon1, Telefon2, Telefon3
- JSON/XML in einer Spalte
- “Wiederholungsgruppen”

Lösung:

1. Wiederholende Werte in **separate Zeilen** aufteilen
2. Oder: **Neue Tabelle** erstellen (bei 1:N oder M:N)

Beispiel: Telefonnummern

Person(ID, Name, Telefon1, Telefon2, Telefon3)
↓
Person(ID, Name) + Telefon(Person_ID, Nummer)

Ausgangstabelle (nicht 1NF):

Kurs_ID	Kursname	Dozenten
DMA01	Datenmanagement	Flath, Müller
BWL01	Einführung BWL	Schmidt

Schritt 1: Wiederholende Werte identifizieren → “Dozenten”

Schritt 2: Aufteilen in atomare Werte:

Kurs_ID	Kursname	Dozent
DMA01	Datenmanagement	Flath
DMA01	Datenmanagement	Müller
BWL01	Einführung BWL	Schmidt

Hinweis: Der Schlüssel hat sich geändert! Jetzt: (Kurs_ID, Dozent)

Quiz: Welche Tabelle ist in 1NF?

Tabelle A:

ID	Name	Skills
1	Anna	Java, Python
2	Ben	SQL

Tabelle B:

ID	Name	Skill
1	Anna	Java
1	Anna	Python
2	Ben	SQL

Tabelle C:

ID	Name	Skill1	Skill2
1	Anna	Java	Python
2	Ben	SQL	NULL

Antwort:

Quiz: Welche Tabelle ist in 1NF?

Tabelle A:

ID	Name	Skills
1	Anna	Java, Python
2	Ben	SQL

Tabelle B:

ID	Name	Skill
1	Anna	Java
1	Anna	Python
2	Ben	SQL

Tabelle C:

ID	Name	Skill1	Skill2
1	Anna	Java	Python
2	Ben	SQL	NULL

Antwort:

- A: ✗ Liste in Zelle
- B: ✓ Atomar!
- C: ✗ Wiederholungsgruppe

Zweite Normalform (2NF)

Definition: 2NF

Eine Relation ist in **2NF**, wenn sie in 1NF ist und jedes Nicht-Schlüsselattribut **voll funktional abhängig** vom **gesamten** Primärschlüssel ist.

Anders gesagt: Keine partiellen Abhängigkeiten!

Wichtig

2NF ist nur relevant bei **zusammengesetzten** Primärschlüsseln!
Bei einfachem PK ist eine 1NF-Relation automatisch in 2NF.

Bestellung_Pos(Best_Nr, Produkt, Kunde, K_Stadt, P_Preis, Menge)

Funktionale Abhängigkeiten:

- Best_Nr, Produkt → Menge ✓ voll abhängig
- Best_Nr → Kunde, K_Stadt ✗ **partiell!**
- Produkt → P_Preis ✗ **partiell!**

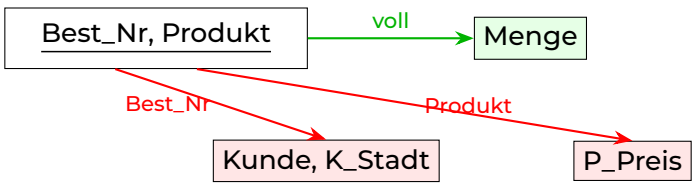

2NF herstellen: Zerlegung

DATA DRIVEN DECISIONS

Lösung: Attribute, die nur von einem Teil des Schlüssels abhängen, in **eigene Tabellen** auslagern.

Vorher (nicht 2NF):

Bestellung_Pos(Best_Nr, Produkt, Kunde, K_Stadt, P_Preis, Menge)

⇓ Zerlegung

Nachher (2NF):

Bestellung(Best_Nr, Kunde, K_Stadt)

Produkt(Produkt, P_Preis)

Best_Position(Best_Nr, Produkt, Menge)

Ergebnis

Jede Tabelle hat nur noch Attribute, die **voll** vom Schlüssel abhängen.

2NF: Schritt-für-Schritt Walkthrough

Ausgangstabelle: Vorlesung(VL_Nr, Dozent_ID, VL_Name, Raum, Dozent_Name)

Schritt 1: FDs identifizieren

- VL_Nr, Dozent_ID → Raum – voll (Dozent kann unterschiedliche Räume haben)
- VL_Nr → VL_Name – **partiell!**
- Dozent_ID → Dozent_Name – **partiell!**

Schritt 2: Partielle FDs auslagern

- Neue Tabelle für VL_Nr → VL_Name
- Neue Tabelle für Dozent_ID → Dozent_Name

Schritt 3: Ergebnis (2NF)

- Vorlesung(VL_Nr, VL_Name)
- Dozent(Dozent_ID, Dozent_Name)
- VL_Dozent(VL_Nr, Dozent_ID, Raum)

Häufiger Fehler: 2NF bei einfachem Schlüssel

DATA DRIVEN DECISIONS

Achtung!

Bei einem **einfachen** (nicht zusammengesetzten) Primärschlüssel gibt es **keine partiellen Abhängigkeiten**.

Beispiel:

Kunde(<u>Kunden_ID</u>, Name, Stadt, PLZ)

- Kunden_ID → Name – voll (Schlüssel hat nur 1 Attribut)
- Kunden_ID → Stadt – voll
- Kunden_ID → PLZ – voll

⇒ Diese Relation ist **automatisch in 2NF**!

Aber: Es könnte trotzdem eine 3NF-Verletzung geben (transitive Abhängigkeit: PLZ → Stadt)

Quiz: Welche NF?

Gegeben: Buchung(Hotel_ID, Gast_ID, Datum, Zimmer, Hotel_Name, Gast_Name)

FDs:

- Hotel_ID, Gast_ID, Datum → Zimmer
- Hotel_ID → Hotel_Name
- Gast_ID → Gast_Name

In welcher Normalform ist die Relation?

A) Nicht in 1NF
B) In 1NF, aber nicht 2NF
C) In 2NF, aber nicht 3NF
D) In 3NF

Quiz: Welche NF?

Gegeben: Buchung(Hotel_ID, Gast_ID, Datum, Zimmer, Hotel_Name, Gast_Name)

FDs:

- Hotel_ID, Gast_ID, Datum → Zimmer
- Hotel_ID → Hotel_Name
- Gast_ID → Gast_Name

In welcher Normalform ist die Relation?

A) Nicht in 1NF
B) In 1NF, aber nicht 2NF
C) In 2NF, aber nicht 3NF
D) In 3NF

Antwort: B) – Partielle Abhängigkeiten vorhanden (Hotel_Name, Gast_Name)

Hands-on

1NF und 2NF anwenden

marimo: 08-normalisierung.py

Aufgaben 8.2 – 8.3

Pause

15 Minuten

Kaffee holen!

Definition: 3NF

Eine Relation ist in **3NF**, wenn sie in 2NF ist und kein Nicht-Schlüsselattribut **transitiv** vom Primärschlüssel abhängt.

Transitive Abhängigkeit:
$A \rightarrow B$ und $B \rightarrow C \Rightarrow C$ hängt **transitiv** von A ab.

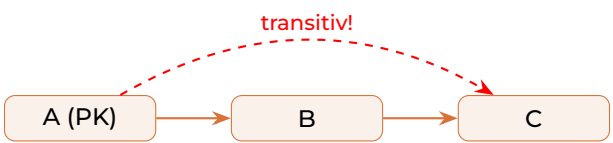

Problem: C ist redundant gespeichert – wenn B sich wiederholt, wird auch C wiederholt!

Bestellung(Best_Nr, Kunde, K_Stadt)

Funktionale Abhängigkeiten:

- Best_Nr → Kunde ✓
- Kunde → K_Stadt (Kunde bestimmt Stadt)
- ⇒ Best_Nr → K_Stadt ✗ **transitiv!**

Redundanz: Wenn Müller 5 Bestellungen hat, steht "München" 5x in der Tabelle.

3NF herstellen: Zerlegung

Lösung: Die transitive Abhängigkeit in eine **eigene Tabelle** auslagern.

Vorher (nicht 3NF):
Bestellung(Best_Nr, Kunde, K_Stadt)

⇓ Zerlegung

Nachher (3NF):
Bestellung(Best_Nr, #Kunde)
Kunde(Kunde, K_Stadt)

Ergebnis

Jedes Nicht-Schlüsselattribut hängt **direkt** (nicht transitiv) vom Schlüssel ab.

Ausgangstabelle (2NF): Mitarbeiter(MA_Nr, Name, Abt_ID, Abt_Name, Abt_Ort)

Schritt 1: Transitive FDs finden

- MA_Nr → Abt_ID – direkt
- Abt_ID → Abt_Name – nicht vom PK!
- Abt_ID → Abt_Ort – nicht vom PK!
- ⇒ MA_Nr → Abt_Name – **transitiv!**
- ⇒ MA_Nr → Abt_Ort – **transitiv!**

Schritt 2: Transitive Attribute auslagern

Schritt 3: Ergebnis (3NF)

- Mitarbeiter(MA_Nr, Name, #Abt_ID)
- Abteilung(Abt_ID, Abt_Name, Abt_Ort)

Beispiel: Universitätssystem

Ausgangstabelle:
Einschreibung(Matrikel, Student_Name, Kurs_ID, Kurs_Name, Dozent_ID, Dozent_Name, Note)

FDs:

- Matrikel → Student_Name
- Kurs_ID → Kurs_Name, Dozent_ID
- Dozent_ID → Dozent_Name
- Matrikel, Kurs_ID → Note

Probleme:

- Partielle Abhängigkeit: Student_Name von Matrikel (nicht 2NF)
- Partielle Abhängigkeit: Kurs_Name, Dozent_ID von Kurs_ID (nicht 2NF)
- Transitive Abhängigkeit: Dozent_Name über Dozent_ID (nicht 3NF)

Normalisierte Tabellen (3NF):

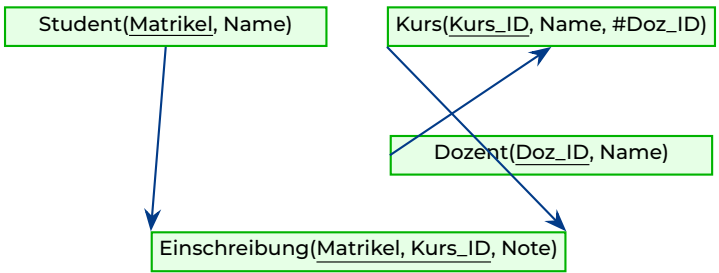

Vorteile:

- Studentendaten nur einmal gespeichert
- Kursdaten nur einmal gespeichert
- Dozentendaten nur einmal gespeichert
- Keine Anomalien mehr möglich!

Ausgangstabelle (nicht normalisiert):

Bestellung_Unnorm(Best_Nr, Kunde, K_Stadt, Produkt, P_Preis, Menge)

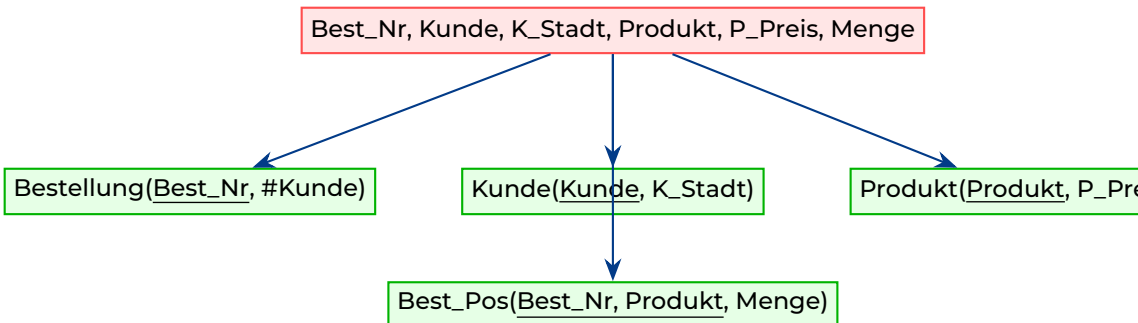

Ergebnis: 4 Tabellen in 3NF – keine Redundanz, keine Anomalien!

Bewerten Sie jede Relation:

Relation	NF?
Film(ID, Titel, Regisseur, Genre, Genre_Beschreibung)	

Quiz: Welche Normalform?

Bewerten Sie jede Relation:

Relation	NF?
Film(ID, Titel, Regisseur, Genre, Genre_Beschreibung)	nicht 3NF
Buch(ISBN, Titel, Autor1, Autor2, Autor3)	

Quiz: Welche Normalform?

DATA DRIVEN DECISIONS

Bewerten Sie jede Relation:

Relation	NF?
Film(ID, Titel, Regisseur, Genre, Genre_Beschreibung)	nicht 3NF
Buch(ISBN, Titel, Autor1, Autor2, Autor3)	nicht 1NF
Bestellung(Best_Nr, Artikel, Preis, Menge, Kunde_Name)	

Quiz: Welche Normalform?

Bewerten Sie jede Relation:

Relation	NF?
Film(ID, Titel, Regisseur, Genre, Genre_Beschreibung)	nicht 3NF
Buch(ISBN, Titel, Autor1, Autor2, Autor3)	nicht 1NF
Bestellung(Best_Nr, Artikel, Preis, Menge, Kunde_Name)	nicht 2NF
Mitarbeiter(MA_ID, Name, Gehalt)	

Quiz: Welche Normalform?

Bewerten Sie jede Relation:

Relation	NF?
Film(ID, Titel, Regisseur, Genre, Genre_Beschreibung)	nicht 3NF
Buch(ISBN, Titel, Autor1, Autor2, Autor3)	nicht 1NF
Bestellung(Best_Nr, Artikel, Preis, Menge, Kunde_Name)	nicht 2NF
Mitarbeiter(MA_ID, Name, Gehalt)	3NF

Erklärungen:

- Film: Genre → Genre_Beschreibung ist transitiv
- Buch: Wiederholungsgruppe (mehrere Autor-Spalten)
- Bestellung: Preis hängt nur von Artikel ab (partiell)
- Mitarbeiter: Alle Attribute hängen direkt vom Schlüssel ab

Häufige Fehler bei der Normalisierung

Fehler 1: FDs übersehen

- Alle Geschäftsregeln beachten!
- “Jeder Kunde hat genau eine Adresse” → FD

Fehler 2: Schlüssel falsch bestimmt

- Schlüssel muss minimal sein
- Alle Attribute bestimmen

Fehler 3: Zu früh aufhören

- 2NF reicht nicht!
- Transitive FDs prüfen

Fehler 4: Zu viel zerlegen

- Nur bei echten Verletzungen zerlegen
- JOINs kosten Performance

Tipp

Bei Unsicherheit: Beispieldaten durchspielen! Tritt Redundanz auf?

Agenda

Boyce-Codd-Normalform (BCNF)

DATA DRIVEN DECISIONS

Definition: BCNF

Eine Relation ist in **BCNF**, wenn für jede nicht-triviale FD $X \rightarrow Y$ gilt: X ist ein **Superschlüssel**.

BCNF ist strenger als 3NF:

- 3NF erlaubt: Schlüsselattribut hängt von Nicht-Schlüssel ab
- BCNF verbietet das

In der Praxis:

- Die meisten 3NF-Relationen sind auch BCNF
- BCNF kann manchmal nicht verlustfrei erreicht werden
- Für Klausuren: 3NF reicht meist!

Merksatz

"Jedes Attribut hängt vom Schlüssel ab, vom ganzen Schlüssel, und von nichts ausser dem Schlüssel." (Codd)

Beispiel: Kurs(Student, Fach, Dozent)

FDs:

- Student, Fach → Dozent – Schlüssel-FD
- Dozent → Fach – Jeder Dozent unterrichtet nur ein Fach

3NF-Prüfung:

- Keine partiellen Abhängigkeiten (Dozent hängt vom ganzen Schlüssel ab)
- Keine transitiven Abhängigkeiten (Dozent ist kein Nicht-Schlüsselattribut in der zweiten FD)
- ⇒ ✓ Ist in 3NF!

BCNF-Prüfung:

- Dozent → Fach – Dozent ist kein Superschlüssel!
- ⇒ ✗ Ist NICHT in BCNF!

Normalformen: Übersicht

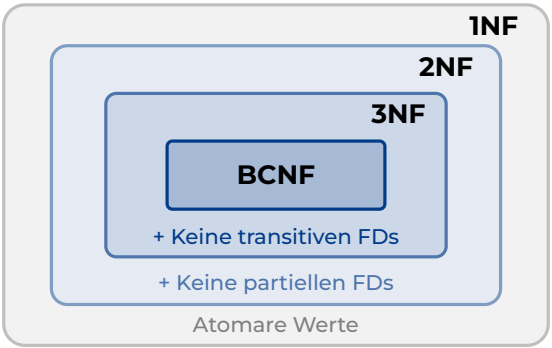

Normalform	Anforderung
1NF	Atomare Werte
2NF	+ Keine partiellen Abhängigkeiten
3NF	+ Keine transitiven Abhängigkeiten
BCNF	+ Jede Determinante ist Superschlüssel

Systematisches Vorgehen:

1. **1NF prüfen:**
   - Sind alle Werte atomar? (Keine Listen, keine Wiederholungsgruppen)
2. **Schlüssel bestimmen:**
   - Welche Attributkombination bestimmt alle anderen?
3. **2NF prüfen:** (nur bei zusammengesetztem Schlüssel)
   - Hängen alle Nicht-Schlüsselattribute vom *ganzen* Schlüssel ab?
4. **3NF prüfen:**
   - Gibt es FDs zwischen Nicht-Schlüsselattributen?
   - Falls ja: transitive Abhängigkeit!

Denormalisierung: Wann und Warum?

DATA DRIVEN DECISIONS

Normalisierung hat auch Nachteile:

- Viele Tabellen → viele JOINs nötig
- JOINs können **Performance kosten**
- Komplexere Abfragen

Denormalisierung = bewusste Einführung von Redundanz

Wann sinnvoll?

- Lesende Zugriffe dominieren (wenig Updates)
- Performance kritisch (z.B. Reporting, Data Warehouse)
- Daten ändern sich selten

Wichtig

Denormalisierung ist eine **bewusste Entscheidung** nach Abwägung!
Erst normalisieren, dann gezielt denormalisieren.

Denormalisierung: Beispiele

DATA DRIVEN DECISIONS

Typische Denormalisierungsstrategien:

1. Berechnete Spalten speichern:

- Statt: SUM(Positionen) bei jeder Abfrage
- Speichern: Bestellung.Gesamtsumme
- Vorteil: Schneller Zugriff
- Nachteil: Bei Änderung nachführen

2. Häufige JOINs vorwegnehmen:

- Statt: Bestellung JOIN Kunde
- Speichern: Kundenname in Bestellung
- Vorteil: Kein JOIN nötig
- Nachteil: Redundanz

Data Warehouse

In analytischen Systemen (OLAP) ist Denormalisierung Standard!
→ “Star Schema”, “Snowflake Schema”

Wann welche Normalform?

Situation	Empfehlung	Grund
OLTP-System	3NF (mindestens)	Datenintegrität
Data Warehouse	1NF/2NF	Leseperformance
Reporting-DB	Denormalisiert	Schnelle Abfragen
Stammdaten	3NF/BCNF	Wenig Änderungen
Bewegungsdaten	3NF	Viele Änderungen

Faustregel:

- **Viele Schreibzugriffe** → Hohe Normalform (3NF)
- **Viele Lesezugriffe** → Ggf. denormalisieren
- **Im Zweifel:** Erst normalisieren, dann messen, dann optimieren

Hands-on

3NF-Normalisierung durchführen

marimo: 08-normalisierung.py

Aufgaben 8.4 – 8.5

Agenda

Zusammenfassung

Funktionale Abhängigkeit:

- A → B = A bestimmt B
- Voll vs. partiell
- Transitiv: A→B→C

Normalformen:

- 1NF: Atomare Werte
- 2NF: Keine partiellen Abhängigkeiten
- 3NF: Keine transitiven Abhängigkeiten

Normalisierungsalgorithmus:

1. FDs identifizieren
2. Schlüssel bestimmen
3. Verletzungen finden
4. Tabelle zerlegen
5. Wiederholen bis 3NF

Denormalisierung:

- Bewusst Redundanz einführen
- Für Performance
- Nach Abwägung!

Normalisierung: Der Algorithmus

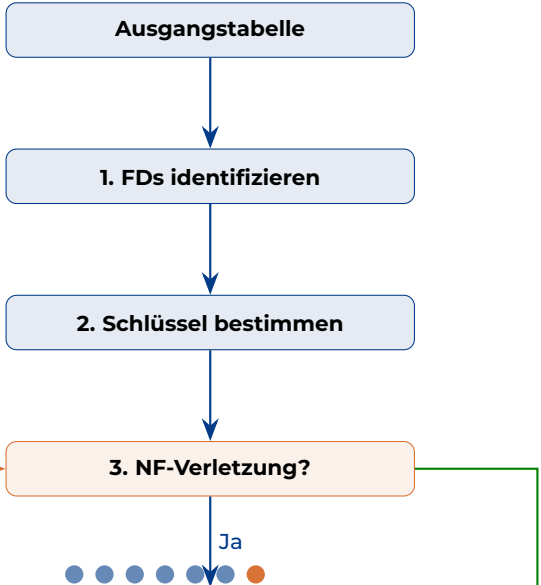

NF	Anforderung	Prüffrage	Lösung
1NF	Atomare Werte	Listen in Zellen? Wiederholungsgruppen?	Aufteilen in Zeilen/Tabellen
2NF	Voll abhängig vom PK	Hängt Attribut von Teil des Schlüssels ab?	Teil-FD auslagern
3NF	Keine transitive FD	FD zwischen Nicht-Schlüssel-Attributen?	Transitive FD auslagern
BCNF	Determinante = Superschlüssel	Determinante kein Schlüssel?	Auslagern

Merksatz (Codd):

> *"Jedes Attribut hängt ab vom Schlüssel, vom ganzen Schlüssel, und von nichts ausser dem Schlüssel – so wahr mir Codd helfe!"*

Vorlesung 9: Joins

- Daten aus mehreren Tabellen verknüpfen
- INNER JOIN, LEFT JOIN, RIGHT JOIN
- Self-Joins
- Join-Performance

Jetzt haben wir gute Tabellen – in Vorlesung 9 lernen wir, sie wieder zusammenzuführen!

Fragen?

christoph.flath@uni-wuerzburg.de