DATA DRIVEN DECISIONS

Sommersemester 2026

Datenmanagement & -analyse

Prof. Dr. Christoph M. Flath
Lehrstuhl für Wirtschaftsinformatik und Business Analytics

Julius-Maximilians-Universität Würzburg

Rückblick: Der Weg zu normalisierten Daten

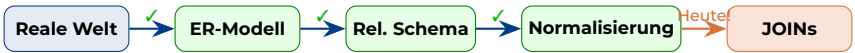

Letzte Session:

- Funktionale Abhängigkeiten
- Normalformen (1NF, 2NF, 3NF)
- Zerlegung in redundanzfreie Tabellen

Diese Session:

- Wie fügen wir die Daten wieder zusammen?
- **JOINs** – das Gegenstück zur Normalisierung!

Nach der Normalisierung:

- Daten sind aufgeteilt
- Keine Redundanz
- Aber: Zusammenhänge verteilt!

Problem:
"Welcher Spieler spielt für welchen Verein?"

→ Information in **zwei Tabellen**!

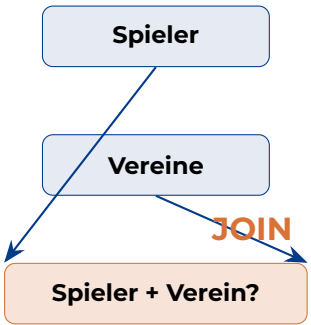

Kernidee

JOIN = Verknüpfung von Zeilen aus verschiedenen Tabellen anhand einer gemeinsamen Bedingung.

Normalisierte Bundesliga-Datenbank:

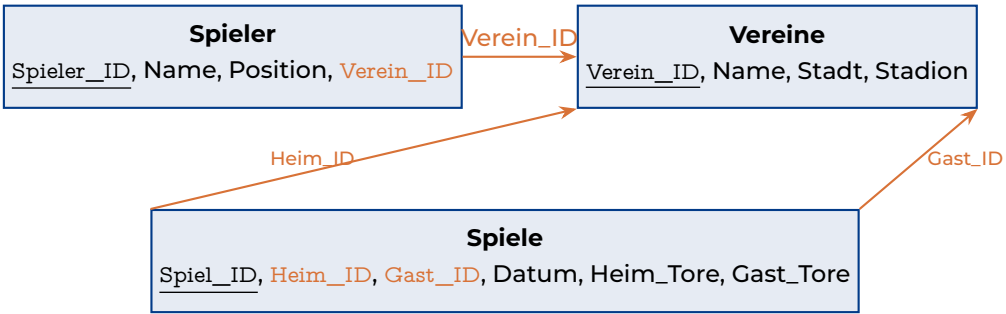

Fragen, die JOINs beantworten:

- Welche Spieler spielen für Bayern München?
- In welchen Stadien fanden Spiele statt?
- Welche Vereine haben noch keine Spieler?

Beispieldaten

Spieler

ID	Name	Pos	V_ID
1	Müller	ST	1
2	Kimmich	MF	1
3	Wirtz	MF	2
4	Tah	DF	2
5	Neuer	TW	1
6	Haaland	ST	NULL

Vereine

ID	Name	Stadt
1	Bayern	München
2	Leverkusen	Leverkusen
3	Dortmund	Dortmund
4	Frankfurt	Frankfurt

Beachte:

- Haaland hat `NULL` als Verein_ID (vereinslos)
- Dortmund und Frankfurt haben keine Spieler in unserer Tabelle

Die JOIN-Familie: Übersicht

INNER JOIN

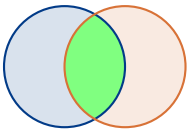

Nur Treffer

LEFT JOIN

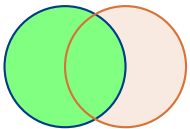

Alle links + Treffer

RIGHT JOIN

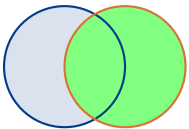

Treffer + alle rechts

FULL OUTER JOIN

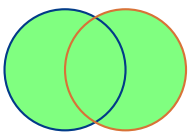

Alle + alle

Agenda

INNER JOIN: Die Schnittmenge

Definition

Der **INNER JOIN** gibt nur die Zeilen zurück, bei denen die Join-Bedingung in **beiden** Tabellen erfüllt ist.

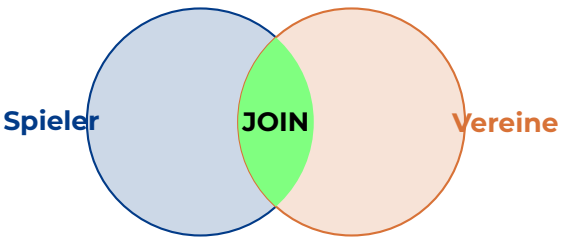

Nur Spieler **mit** passendem Verein

Merke: Zeilen ohne Treffer werden **nicht** ausgegeben!

Explizite Syntax (empfohlen):

```
SELECT s.Name, v.Name AS Verein
FROM Spieler s
INNER JOIN Vereine v ON s.Verein_ID = v.Verein_ID;
```

Ergebnis:

Name	Verein
Müller	Bayern
Kimmich	Bayern
Wirtz	Leverkusen
Tah	Leverkusen
Neuer	Bayern

Beachte: Haaland fehlt (NULL) und Dortmund/Frankfurt fehlen (keine Spieler)!

INNER JOIN: Wie funktioniert es?

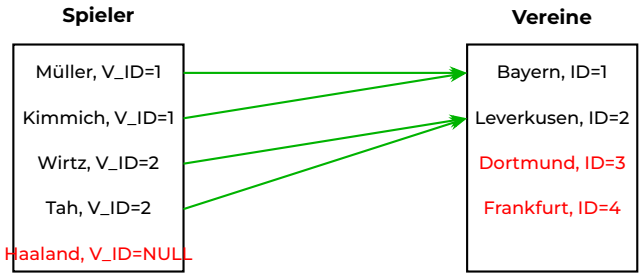

Ergebnis: 4 Zeilen (nur Treffer)

INNER JOIN: Alte vs. Neue Syntax

DATA DRIVEN DECISIONS

Explizite Syntax (SQL-92):

```sql
SELECT s.Name, v.Name
FROM Spieler s
INNER JOIN Vereine v
  ON s.Verein_ID = v.Verein_ID;
```

✓ Klar erkennbar als JOIN
✓ Trennung von Join und Filter
✓ Empfohlener Standard

Implizite Syntax (alte Variante):

```sql
SELECT s.Name, v.Name
FROM Spieler s, Vereine v
WHERE s.Verein_ID = v.Verein_ID;
```

✗ JOIN versteckt in WHERE
✗ Leicht vergessbar
✗ Wird kartesisches Produkt bei Fehler

Empfehlung

Immer die **explizite** JOIN-Syntax verwenden! Klarer, sicherer, wartbarer.

INNER JOIN: Mehrere Tabellen

DATA DRIVEN DECISIONS

Problem: Alle Spiele mit Heim- und Gastverein-Namen?

```
SELECT
    sp.Datum,
    h.Name AS Heim,
    sp.Heim_Tore,
    sp.Gast_Tore,
    g.Name AS Gast
FROM Spiele sp
INNER JOIN Vereine h ON sp.Heim_ID = h.Verein_ID
INNER JOIN Vereine g ON sp.Gast_ID = g.Verein_ID;
```

Beachte:

- Zwei JOINs auf die **gleiche** Tabelle (Vereine)
- Unterschiedliche Aliase (h für Heim, g für Gast)
- JOINs werden von links nach rechts ausgeführt

Quiz: INNER JOIN verstehen

DATA DRIVEN DECISIONS

Gegeben:

- Spieler: 6 Zeilen (5 mit Verein, 1 mit NULL)
- Vereine: 4 Zeilen

Wie viele Zeilen liefert dieser Query?

```
SELECT s.Name, v.Name
FROM Spieler s
INNER JOIN Vereine v ON s.Verein_ID = v.Verein_ID;
```

A) 4 Zeilen (so viele wie Vereine)
B) 5 Zeilen (Spieler mit Verein)
C) 6 Zeilen (alle Spieler)
D) 24 Zeilen (kartesisches Produkt)

Quiz: INNER JOIN verstehen

DATA DRIVEN DECISIONS

Gegeben:

- Spieler: 6 Zeilen (5 mit Verein, 1 mit NULL)
- Vereine: 4 Zeilen

Wie viele Zeilen liefert dieser Query?

```
SELECT s.Name, v.Name
FROM Spieler s
INNER JOIN Vereine v ON s.Verein_ID = v.Verein_ID;
```

A) 4 Zeilen (so viele wie Vereine)
B) 5 Zeilen (Spieler mit Verein)
C) 6 Zeilen (alle Spieler)
D) 24 Zeilen (kartesisches Produkt)

Antwort: B) – Nur Spieler mit passendem Verein (5 Treffer)

Hands-on

INNER JOIN anwenden

marimo: 09-joins.py

Aufgaben 9.1 – 9.2

Agenda

LEFT JOIN: Alle von links erhalten

DATA DRIVEN DECISIONS

Definition

Der **LEFT JOIN** gibt **alle** Zeilen der linken Tabelle zurück, auch wenn kein Treffer in der rechten Tabelle existiert. Fehlende Werte werden mit `NULL` aufgefüllt.

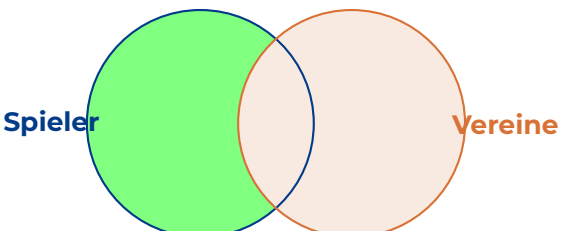

Alle Spieler, auch ohne Verein

LEFT JOIN: Syntax und Beispiel


```sql
SELECT s.Name, v.Name AS Verein
FROM Spieler s
LEFT JOIN Vereine v ON s.Verein_ID = v.Verein_ID;
```

Ergebnis:

Name	Verein
Müller	Bayern
Kimmich	Bayern
Wirtz	Leverkusen
Tah	Leverkusen
Neuer	Bayern
Haaland	NULL

Neu: Haaland erscheint jetzt – mit NULL für Verein!

LEFT JOIN: Fehlende Datensätze finden

Häufiges Muster: “Welche Spieler haben keinen Verein?”

```sql
SELECT s.Name
FROM Spieler s
LEFT JOIN Vereine v ON s.Verein_ID = v.Verein_ID
WHERE v.Verein_ID IS NULL;
```

Ergebnis:

Name
Haaland

Wichtiges Muster

`LEFT JOIN ... WHERE rechts.ID IS NULL` = “Finde Zeilen ohne Treffer”

RIGHT JOIN: Alle von rechts erhalten

DATA DRIVEN DECISIONS

Definition

Der **RIGHT JOIN** gibt **alle** Zeilen der rechten Tabelle zurück, auch wenn kein Treffer in der linken Tabelle existiert.

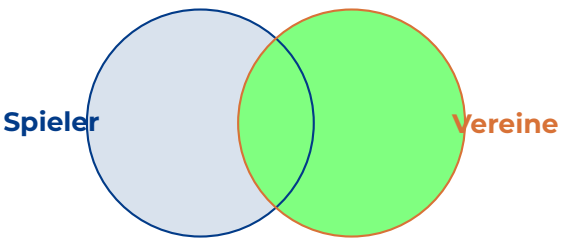

Alle Vereine, auch ohne Spieler

Hinweis: RIGHT JOIN ist selten – meist kann man die Tabellen tauschen und LEFT JOIN nutzen.

“Welche Vereine haben (k)eine Spieler?”

```
SELECT v.Name AS Verein, COUNT(s.Spieler_ID) AS Anzahl
FROM Spieler s
RIGHT JOIN Vereine v ON s.Verein_ID = v.Verein_ID
GROUP BY v.Name;
```

Ergebnis:

Verein	Anzahl
Bayern	3
Leverkusen	2
Dortmund	0
Frankfurt	0

Neu: Dortmund und Frankfurt erscheinen mit Anzahl 0!

FULL OUTER JOIN: Alles erhalten

Definition

Der **FULL OUTER JOIN** gibt **alle** Zeilen beider Tabellen zurück. Fehlende Werte werden mit `NULL` aufgefüllt.

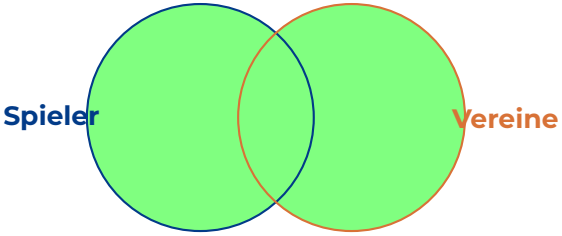

Alle Spieler + Alle Vereine

Hinweis zur Kompatibilität

FULL OUTER JOIN wird von DuckDB und PostgreSQL unterstützt. SQLite

JOIN-Typen: Zusammenfassung

JOIN-Typ	Beschreibung	Ohne Match links	Ohne Match rechts
INNER JOIN	Nur Treffer	✗ ausgeschlossen	✗ ausgeschlossen
LEFT JOIN	Alle links, Treffer rechts	✓ mit NULL	✗ ausgeschlossen
RIGHT JOIN	Treffer links, alle rechts	✗ ausgeschlossen	✓ mit NULL
FULL OUTER	Alle beider Seiten	✓ mit NULL	✓ mit NULL

Praxis-Empfehlung:

- **INNER JOIN**: Standard, wenn nur vollständige Daten benötigt
- **LEFT JOIN**: Wenn die linke Tabelle komplett bleiben soll
- **RIGHT JOIN**: Selten – lieber Tabellen tauschen und LEFT nutzen
- **FULL OUTER**: Selten – bei Datenabgleich/-vergleich

Quiz: Welcher JOIN?

Anforderung: “Liste alle Vereine mit der Anzahl ihrer Spieler. Vereine ohne Spieler sollen mit 0 erscheinen.”

Welcher JOIN ist korrekt?

A) `Vereine INNER JOIN Spieler`
B) `Spieler LEFT JOIN Vereine`
C) `Vereine LEFT JOIN Spieler`
D) `Spieler INNER JOIN Vereine`

Quiz: Welcher JOIN?

Anforderung: “Liste alle Vereine mit der Anzahl ihrer Spieler. Vereine ohne Spieler sollen mit 0 erscheinen.”

Welcher JOIN ist korrekt?

A) Vereine INNER JOIN Spieler
B) Spieler LEFT JOIN Vereine
C) Vereine LEFT JOIN Spieler
D) Spieler INNER JOIN Vereine

Antwort: C) – Alle Vereine (links) erhalten, auch ohne Spieler-Treffer.

```
SELECT v.Name, COUNT(s.Spieler_ID) AS Anzahl
FROM Vereine v
LEFT JOIN Spieler s ON v.Verein_ID = s.Verein_ID
GROUP BY v.Name;
```

Hands-on

LEFT JOIN und fehlende Daten finden

marimo: 09-joins.py

Aufgaben 9.3 – 9.4

Pause

15 Minuten

Kaffee holen!

Agenda

Self-Join: Eine Tabelle mit sich selbst

Definition

Ein **Self-Join** verknüpft eine Tabelle mit **sich selbst**. Dabei werden Aliase verwendet, um die beiden "Kopien" zu unterscheiden.

Typische Anwendungsfälle:

- Hierarchien (Mitarbeiter → Vorgesetzter)
- Vergleiche innerhalb einer Tabelle
- Beziehungen zwischen Elementen der gleichen Menge
- Graphen und Netzwerke

Self-Join: Beispiel Hierarchie

Szenario: Mitarbeiter mit ihren Vorgesetzten

MA_ID	Name	Chef_ID
1	Müller (CEO)	NULL
2	Schmidt	1
3	Weber	1
4	Fischer	2
5	Bauer	2

```sql
SELECT m.Name AS Mitarbeiter, c.Name AS Chef
FROM Mitarbeiter m
LEFT JOIN Mitarbeiter c ON m.Chef_ID = c.MA_ID;
```

Ergebnis: Schmidt → Müller, Weber → Müller, Fischer → Schmidt, ...

Self-Join: Spiele (Heim vs. Gast)

Problem: Spiele mit Heim- und Gastnamen (beide aus Vereine)

```
SELECT
    sp.Datum,
    h.Name AS Heim,
    sp.Heim_Tore || ':' || sp.Gast_Tore AS Ergebnis,
    g.Name AS Gast
FROM Spiele sp
JOIN Vereine h ON sp.Heim_ID = h.Verein_ID
JOIN Vereine g ON sp.Gast_ID = g.Verein_ID;
```

Ergebnis:

Datum	Heim	Ergebnis	Gast
2026-03-15	Bayern	2:1	Dortmund
2026-03-16	Leverkusen	3:0	Frankfurt

Beachte: Zwei JOINs auf Vereine mit unterschiedlichen Aliasen (h, g)!

Self-Join: Spieler im gleichen Verein

Problem: Welche Spieler spielen im gleichen Verein?

```sql
SELECT
    s1.Name AS Spieler1,
    s2.Name AS Spieler2,
    v.Name AS Verein
FROM Spieler s1
JOIN Spieler s2 ON s1.Verein_ID = s2.Verein_ID
                AND s1.Spieler_ID < s2.Spieler_ID
JOIN Vereine v ON s1.Verein_ID = v.Verein_ID;
```

Ergebnis:

Spieler1	Spieler2	Verein
Müller	Kimmich	Bayern
Müller	Neuer	Bayern
Kimmich	Neuer	Bayern
Wirtz	Tah	Leverkusen

Wichtig: s1.ID < s2.ID verhindert Duplikate und Selbst-Paare!

Motivation: Self-Joins ermöglichen einfache Graph-Operationen!

Graph als Edge-List:

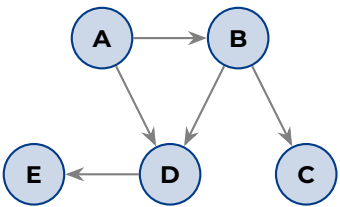

Als Tabelle:

von	nach
A	B
A	D
B	C
B	D
D	E

Idee: Jede Kante ist eine Zeile mit (Quelle, Ziel).

Beispiel: Freundschaftsbeziehungen

```
CREATE TABLE friendships (
    person_a TEXT,
    person_b TEXT
);
```

person_a	person_b
Alice	Bob
Alice	Carol
Bob	Dave
Carol	Dave
Carol	Eve

Frage: Wer sind die “Freunde von Freunden” von Alice?

Self-Join: Freunde von Freunden

2-Hop-Pfad mit Self-Join:

```sql
SELECT DISTINCT f2.person_b AS friend_of_friend
FROM friendships f1
JOIN friendships f2 ON f1.person_b = f2.person_a
WHERE f1.person_a = 'Alice'
  AND f2.person_b <> 'Alice';
```

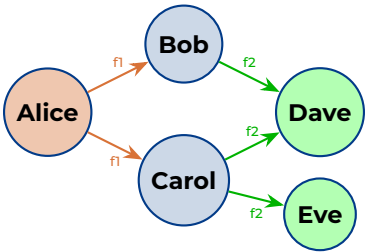

Ergebnis: Dave, Eve (Freunde von Freunden)

Was SQL nicht kann: Graph-Limitierungen

DATA DRIVEN DECISIONS

Grenzen von SQL bei Graphen:

Geht mit SQL:

- Direkte Nachbarn (1 Hop)
- 2-Hop-Pfade (Self-Join)
- N-Hop-Pfade (N JOINs)
- Zyklen fester Länge

Geht NICHT (oder schwer):

- Kürzester Pfad beliebiger Länge
- PageRank
- Zusammenhangskomponenten
- Transitive Hülle (alle Pfade)

Fazit

Für komplexe Graph-Analysen: Spezialisierte Tools nutzen!

- **Python:** NetworkX
- **Datenbanken:** Neo4j, Amazon Neptune
- **Big Data:** Apache Spark GraphX

SQL kann mehr mit “Recursive CTE”:

Damit möglich:

- Transitive Hülle (alle erreichbaren Knoten)
- Hierarchie-Traversierung beliebiger Tiefe
- Pfade in Graphen

Hinweis: Wird in Session 10 (Subqueries & CTEs) vertieft.

Agenda

Join-Performance: Warum es wichtig ist

JOINs können teuer sein:

Kartesisches Produkt:

- Ohne Bedingung: $n \times m$ Kombinationen
- 1.000 $\times$ 1.000 = 1.000.000 potentielle Paare
- Datenbankoptimizer reduziert das – aber nur mit Index!

Join-Algorithmen: Überblick

Wie die Datenbank JOINs ausführt:

Algorithmus	Funktionsweise	Wann gut?
Nested Loop	Für jede Zeile links: durchsuche rechts	Kleine Tabellen, Index rechts
Hash Join	Hash-Tabelle bauen, dann matchen	Große Tabellen, kein Index
Merge Join	Beide sortiert, parallel durchlaufen	Bereits sortierte Daten

Der Optimizer wählt automatisch!
Aber: Wir können helfen durch:

- Indizes auf Join-Spalten
- Sinnvolle Join-Reihenfolge
- Vermeidung von Funktionen auf Join-Spalten

Indizes für JOIN-Performance

Regel

Join-Spalten sollten **indiziert** sein – besonders die Fremdschlüssel!

Ohne Index:

- Datenbank muss **alle** Zeilen durchsuchen
- Bei großen Tabellen: sehr langsam

Mit Index:

- Direkter Zugriff auf passende Zeilen
- Logarithmische statt linearer Suche

EXPLAIN: Query-Plan analysieren

Mit EXPLAIN sehen, was die Datenbank plant:

```
EXPLAIN
SELECT s.Name, v.Name
FROM Spieler s
JOIN Vereine v ON s.Verein_ID = v.Verein_ID;
```

Typische Operatoren im Query-Plan:

- `SCAN / SEQ_SCAN`: Alle Zeilen durchlaufen (langsam bei großen Tabellen)
- `INDEX_SCAN`: Index-Lookup (schnell)
- `HASH_JOIN`: Hash-basierter Join
- `MERGE_JOIN`: Sortier-basierter Join

Hinweis: Die genaue Ausgabe variiert je nach Datenbank (DuckDB, PostgreSQL, SQLite, ...)

Best Practices: JOINs optimieren

1. Indizes erstellen:

- Alle Fremdschlüssel indizieren
- Häufig gefilterte Spalten indizieren

2. Früh filtern:

- WHERE-Bedingungen so früh wie möglich
- Weniger Zeilen im JOIN = schneller

3. Nur benötigte Spalten:

- `SELECT *` vermeiden
- Explizit nur benötigte Spalten auswählen

4. Join-Reihenfolge beachten:

- Kleine Tabelle zuerst (bei manchen Datenbanken)
- Optimizer macht das meist automatisch

CROSS JOIN: Das kartesische Produkt

DATA DRIVEN DECISIONS

Definition

Ein **CROSS JOIN** erzeugt alle möglichen Kombinationen – **ohne** Bedingung.

Selten gewollt, aber nützlich für:

- Kalender/Zeitreihen generieren
- Alle Kombinationen erzeugen
- Test-Datensätze erstellen

Links (3)	Rechts (4)	CROSS (12)
A	1	A-1, A-2, A-3, A-4
B	2	B-1, B-2, B-3, B-4
C	3	C-1, C-2, C-3, C-4
	4	

Kurzschreibweisen (mit Vorsicht zu genießen):

USING – wenn Spaltenname identisch:

```
SELECT * FROM Spieler
JOIN Vereine USING (Verein_ID);
```

✓ Kurz und lesbar bei gleichnamigen Spalten

NATURAL JOIN – automatisch nach gleichen Namen:

```
SELECT * FROM Spieler
NATURAL JOIN Vereine;
```

✗ Gefährlich! Joined auf **alle** gleichnamigen Spalten – auch unbeabsichtigt!

Empfehlung

USING ist akzeptabel. NATURAL JOIN vermeiden – zu implizit, fehleranfällig.

Hands-on

Self-Joins und Performance

marimo: 09-joins.py

Aufgaben 9.5 – 9.7

Agenda

Zusammenfassung: JOIN-Typen

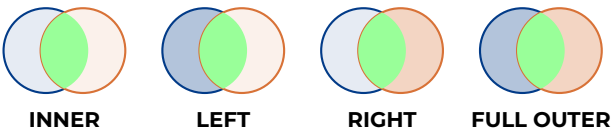

- **INNER JOIN**: Nur Treffer beider Seiten
- **LEFT JOIN**: Alle links + Treffer (NULL wenn kein Match)
- **RIGHT JOIN**: Treffer + Alle rechts (selten benötigt)
- **FULL OUTER**: Alle beider Seiten (nicht in SQLite)

Zusammenfassung: Wichtige Muster

1. Fehlende Daten finden:

- `LEFT JOIN ... WHERE rechts.ID IS NULL`
- “Spieler ohne Verein”, “Vereine ohne Spieler”

2. Self-Join für interne Beziehungen:

- Gleiche Tabelle mit verschiedenen Aliasen
- Hierarchien, Vergleiche, Graphen

3. Mehrere JOINs verketten:

- `FROM A JOIN B JOIN C`
- Spiele mit Heim- und Gast-Vereinsnamen

4. Performance beachten:

- Indizes auf Fremdschlüsseln
- EXPLAIN zur Analyse

Cheat Sheet: JOIN-Syntax

DATA DRIVEN DECISIONS

Muster	SQL-Syntax
INNER JOIN	`FROM A INNER JOIN B ON A.id = B.a_id`
LEFT JOIN	`FROM A LEFT JOIN B ON A.id = B.a_id`
RIGHT JOIN	`FROM A RIGHT JOIN B ON A.id = B.a_id`
Self-Join	`FROM T t1 JOIN T t2 ON t1.x = t2.y`
Mehrfach-Join	`FROM A JOIN B ON ... JOIN C ON ...`
Fehlende finden	`LEFT JOIN ... WHERE B.id IS NULL`
USING	`FROM A JOIN B USING (gemeinsame_spalte)`

Merksatz:

"Die linke Tabelle bestimmt die Grundmenge bei LEFT JOIN – alle ihre Zeilen bleiben erhalten."

Häufige Fehler vermeiden

DATA DRIVEN DECISIONS

✗ **Fehler:**

- JOIN ohne ON-Bedingung
  → Kartesisches Produkt!
- Falsche Spalte im JOIN
  → Unerwartete Ergebnisse
- LEFT statt INNER verwechselt
  → NULL-Werte unerwartet
- Fehlende Aliase bei Self-Join
  → Syntax-Fehler

✓ **Best Practices:**

- Immer explizite ON-Klausel
- Aliase bei mehrdeutigen Spaltennamen
- Tabellenname.Spalte bei JOINs
- EXPLAIN bei langsamen Queries
- Indizes auf FK-Spalten

Tipp

Bei unerwarteten Ergebnissen: Erst ohne WHERE prüfen, dann Filter hinzufügen.

Ausblick: Nächste Vorlesung

Vorlesung 10: Subqueries, Views & Transaktionen

- Subqueries: Abfragen in Abfragen
- Common Table Expressions (WITH)
- Views: Virtuelle Tabellen
- ACID und Transaktionen

Mit JOINs und Subqueries sind fast alle SQL-Abfragen möglich!

Fragen?

christoph.flath@uni-wuerzburg.de